

LẬP TRÌNH PHÂN TÍCH DỮ LIỆU

BÀI TẬP 2 - Thu thập và Tổ chức Dữ liệu

Tuần thực hiện	Tuần 7
Liên kết LO	LO1 (hàm/module Python), LO2 (NumPy), LO3 (Pandas: tạo lập, đọc/ghi CSV/Excel/JSON/Parquet)
Giai đoạn quy trình	4.1 (hoàn thiện thu thập) → chuyển tiếp sang 4.2
Sản phẩm nộp	Bộ dữ liệu thô + dữ liệu đã tổ chức lại (raw/ và processed/), script thu thập dữ liệu, Data Dictionary sơ bộ

1. Mục tiêu bài tập

- Thu thập được bộ dữ liệu thực tế về bất động sản (ưu tiên từ Network CafeLand: nhadat.cafeland.vn cho tin rao vặt, map.cafeland.vn cho dữ liệu quy hoạch/vị trí, cafeland.vn cho tin tức/chỉ số thị trường).
- Đạt yêu cầu tối thiểu của đề án: ≥ 5.000 dòng và ≥ 8 biến (kết hợp nhiều lần thu thập hoặc nhiều nguồn nếu một nguồn không đủ).
- Tổ chức dữ liệu bằng Pandas: đọc/ghi nhiều định dạng, đặt cấu trúc thư mục dự án rõ ràng, viết Data Dictionary mô tả từng biến.

2. Hoạt động tại lớp (60 phút)

T.Gian	Hoạt động	Nội dung / Kết quả cần đạt
0–10'	Ôn tập kỹ thuật thu thập	Demo nhanh 2 cách thu thập dữ liệu từ trang dạng CafeLand: (a) requests + BeautifulSoup/pandas.read_html cho trang tĩnh, (b) đọc file/API mẫu nếu trang có giới hạn.
10–35'	Thực hành viết script thu thập	Từng nhóm viết/hoàn thiện script Python (hàm hóa từng bước theo LO1) để lấy dữ liệu tin đăng/dự án: tiêu đề, giá, diện tích, vị trí (quận/huyện, phường/xã), loại hình BĐS, số phòng, ngày đăng, link nguồn. Lưu dữ liệu thô vào CSV/JSON ngay khi chạy thử.
35–50'	Tổ chức & mô tả dữ liệu bằng Pandas	Đọc dữ liệu thô vào DataFrame; kiểm tra nhanh .info()/describe(); dùng NumPy để chuẩn hóa vài trường số (ví dụ tách đơn vị giá VNĐ/tỷ, diện tích m ²); lưu bản processed sang Parquet hoặc Excel để so sánh dung lượng/tốc độ đọc.
50–60'	Chia sẻ khó khăn nhóm	Mỗi nhóm nêu 1 khó khăn kỹ thuật gặp phải khi thu thập từ CafeLand (ví dụ trang tải động, phân trang, dữ liệu thiếu trường) và giải pháp đã thử; giảng viên tổng hợp gợi ý chung cho cả lớp.

3. Gợi ý cấu trúc bộ dữ liệu CafeLand

- Bảng tin đăng bất động sản (từ nhadat.cafeland.vn): mã tin, tiêu đề, loại hình (căn hộ/nhà phố/đất nền/kho xưởng...), giá, diện tích, số phòng ngủ, số tầng, hướng nhà, tỉnh/thành, quận/huyện, phường/xã, tình trạng pháp lý, ngày đăng, tên môi giới/sàn.
- Bảng dự án bất động sản (từ cafeland.vn/du-an): tên dự án, chủ đầu tư, loại hình, giá thấp nhất, địa chỉ, quy mô, tiến độ.
- Dữ liệu vị trí/tiện ích (tham khảo cách CafeLand Map tổ chức): tọa độ, khoảng cách đến trường học/y tế/chợ/giao thông - có thể mô phỏng bằng dữ liệu địa lý mở nếu không truy cập được API gốc.
- Nếu dữ liệu từ CafeLand không đủ số dòng, bổ sung/gộp với dữ liệu cùng cấu trúc từ batdongsan.com.vn hoặc nhatot.com, ghi rõ nguồn cho từng dòng dữ liệu (thêm cột "nguồn").

4. Nhiệm vụ về nhà (sau Tuần 7, hoàn thiện trước buổi Bài tập 3)

1. Hoàn thiện thu thập đủ ≥ 5.000 dòng, ≥ 8 biến; lưu dữ liệu thô (raw) và dữ liệu đã tổ chức (processed) theo cấu trúc thư mục rõ ràng (data/raw, data/processed).
2. Viết Data Dictionary: tên biến, kiểu dữ liệu, đơn vị, ý nghĩa, nguồn gốc (CafeLand hay nguồn bổ sung).
3. Kiểm tra chất lượng dữ liệu ban đầu: tỷ lệ giá trị thiếu theo từng cột, số dòng trùng lặp, kiểu dữ liệu chưa nhất quán (ví dụ giá ghi dạng chữ "2,5 tỷ").
4. Đóng gói script thu thập dữ liệu thành hàm/module có thể chạy lại (README ngắn hướng dẫn cách chạy).

5. Tiêu chí đánh giá nhanh

Mức độ	Biểu hiện cụ thể trong bài tập
Chưa đạt	Không thu thập được dữ liệu thực tế hoặc dữ liệu không liên quan đến vấn đề đã định nghĩa; thiếu số dòng/biến tối thiểu nghiêm trọng.
Đạt yêu cầu	Đạt yêu cầu tối thiểu về quy mô dữ liệu; script thu thập chạy lại được; Data Dictionary đầy đủ; đã đánh giá sơ bộ chất lượng dữ liệu.
Xuất sắc	Dữ liệu phong phú, đối chiếu/bổ sung hợp lý từ nhiều nguồn có ghi chú minh bạch; script được hàm hóa sạch, dễ tái sử dụng; đã phát hiện và ghi nhận rõ các vấn đề chất lượng dữ liệu cần xử lý ở bước EDA.